

«Толмач»: что умеет система

Лабораторная работа № 2 · вариант 4 · распознавание языка текста (русский и немецкий, документы HTML)

«Толмач» определяет, на каком языке — русском или немецком — написан HTML-документ. Каждый документ разбирается сразу тремя методами: методом N-грамм (Кавнар — Тренкл), алфавитным и нейросетевым. Итоговый ответ — голосование трёх методов. По тестовой коллекции система считает точность и быстродействие каждого метода и ставит два опыта, в которых методы начинают различаться: короткий текст и смесь двух языков.

Зачем это нужно: прежде чем переводить текст, индексировать его в поисковой системе или направлять специалисту, нужно знать язык — от него зависят морфология, словари и дальнейший маршрут документа.

В системе пять рабочих страниц. Кроме них есть версия для печати, «Справка» и игровая страница «Партия с Пафнутием» (шахматы), которая ниже не описывается. Запуск: **python run.py**, адрес **http://127.0.0.1:8010/**.

Страница	Адрес	Для чего
Коллекция	/	результат по всем документам, итог, сохранение и печать
Разбор документа	/document/<файл>	решение каждого метода и на чём оно основано
Сравнение методов	/compare	точность, быстродействие, опыты с длиной и смесью
Профили языков	/profiles	поисковые образы языков, алфавиты, обучение сети
Свой текст	/check	распознать вставленный текст или файл

1. Коллекция <http://127.0.0.1:8010/>

На главной странице три карточки: «Обучающий корпус» (файлов, объём, букв по каждому языку; методичка требует 20–120 Кб), «Итог прогона» (точность и время на документ у каждого метода и у согласованного решения) и «Действия»: «Распознать заново», сохранение результата в CSV, JSON и TXT и «Печать» — версия страницы без навигации. Ниже — таблица по документам: имя файла (активная ссылка на исходный HTML), число букв, эталонный язык, ответ каждого метода с расстоянием, итог (с пометкой «спор», если методы разошлись) и ссылка на разбор. В конце — сводная статистика.

Пример. Корпус: русский — 46 файлов, 78,6 Кб, 36 716 букв; немецкий — 6 файлов, 41,1 Кб, 34 620 букв. По буквам объёмы почти равны, по байтам — нет: кириллица в UTF-8 занимает 2 байта, латиница — 1.

Коллекция — 20 документов (10 русских и 10 немецких), все распознаны верно всеми методами. Время на документ: N-грамм — 8,28 мс, алфавитный — 0,39 мс, нейросетевой — 4,76 мс, согласованное решение — 13,43 мс.

Как это работает. Распознавание идёт в три шага.

- **Предобработка.** Из HTML удаляются теги и содержимое script и style, раскрываются сущности (& → &), текст приводится к нижнему регистру, всё, что не буква, заменяется пробелом; ä, ö, ü, ß сохраняются, Unicode приводится к форме NFC.
- **Сравнение образов.** Для каждого языка заранее построен поисковый образ языка (ПОЯ). По тем же правилам строится поисковый образ документа (ПОД), и каждый метод считает расстояние от ПОД до каждого ПОЯ, приведённое к отрезку [0; 1].
- **Решение.** Метод выбирает ближайший язык. Итог — большинство голосов; при равенстве побеждает метод с наибольшей уверенностью:

$$\text{уверенность} = (d_2 - d_1) / d_2, \text{ где } d_1 \leq d_2 \text{ — два наименьших расстояния}$$

Время согласованного решения — сумма времён трёх методов: чтобы проголосовать, нужно выполнить каждый.

2. Разбор документа /document/<файл>

Для одного документа видны язык, согласие методов, совпадение с эталоном и общее время. Для каждого метода — расстояния до обоих языков с полосами, уверенность, время и то, на чём основано решение: у метода N-грамм — самые частые N-граммы документа и сколько их нашлось в профиле каждого языка, у алфавитного — доля букв документа из алфавита языка и «чужие» буквы, у нейросети — вероятности на выходе и признаки, сильнее всего повлиявшие на ответ.

Пример. ru-03-mayak.html «Маяки и морская навигация», 2 411 букв:

- N-грамм: $d(\text{рус.}) = 0,342$, $d(\text{нем.}) = 0,997$; из 300 N-грамм документа в профиле русского нашлось 224, немецкого — 1; уверенность 66 %;
- алфавитный: 0,058 и 1,000; 100 % букв — из русского алфавита; уверенность 94 %;
- нейросеть: $P(\text{рус.}) = 0,99998$, расстояния 0,000 и 1,000; сильнее всего повлияли «_н», «м», «_с», «л», «б».

Все три метода — русский; общее время — около 6 мс.

Как это работает. У методов разные образы языка и разные меры расстояния.

Метод N-грамм. Каждое слово обрамляется заполнителем («_слово_»), из него извлекаются все подстроки длиной от 1 до 5 символов; они сортируются по убыванию частоты, и первые 300 образуют профиль, а номер в списке — ранг. По закону Ципфа самые частые N-граммы определяются языком, а не темой текста. Расстояние — мера несовпадения позиций (out-of-place):

$$d = \sum_g \Delta(g) / (|\text{ПОД}| \cdot h), \quad \Delta(g) = |r_{\text{док}}(g) - r_{\text{яз}}(g)|$$

где $r_{\text{док}}(g)$ и $r_{\text{яз}}(g)$ — ранги N-граммы g в профилях документа и языка; если N-граммы нет в профиле языка, $\Delta(g) = h = 300$ — наибольший штраф.

Алфавитный метод. Профиль — относительные частоты букв $p(\text{буква}) = n(\text{буква}) / n(\text{все буквы})$. Расстояние — половина манхэттенского расстояния (расстояние полной вариации):

$$d(p, q) = \frac{1}{2} \cdot \sum_k |p_k - q_k|$$

Буква, которой нет в языке, отдаёт в сумму всю свою частоту, поэтому при разных алфавитах расстояние до «чужого» языка близко к 1.

Нейросетевой метод. Документ описывается частотами 399 символьных N-грамм длиной 1–3 (с пробелом: «_n» — буква «н» в начале слова). Их принимает многослойный персептрон с 32 скрытыми нейронами:

$$h = \tanh(x \cdot W_1 + b_1), \quad P = \text{softmax}(h \cdot W_2 + b_2), \quad P_i = e^{z(i)} / \sum_j e^{z(j)}, \quad d = 1 - P(\text{язык})$$

Функция softmax превращает выходы сети в вероятности, в сумме дающие 1; расстояние $1 - P$ позволяет сравнивать сеть с двумя другими методами по одному правилу «побеждает наименьшее расстояние».

Почему у сети в таблице нули. Это не сбой: кириллица и латиница разделяют языки полностью, и обучение доводит разность выходов сети до $\approx 10,9$, где выигрыш в функции потерь уравнивается L2-штрафом. Отсюда $P \approx 0,99998$ у любого документа, а расстояние $1 - P \approx 2 \cdot 10^{-5}$ при трёх знаках после запятой показывается как 0,000. Что сеть действительно реагирует на текст, видно по смеси языков: $P(\text{нем.})$ растёт плавно — 0,13 при 45 % немецкого текста, 0,51 при 50 %, 0,86 при 55 %; а у той же сети со случайными весами, до обучения, $P(\text{рус.})$ на документах коллекции — от 0,26 до 0,81.

3. Сравнение методов /compare

Методичка требует сравнить методы по точности и затраченному времени. На странице — таблица: точность, верных ответов и ошибок, миллисекунд на документ, документов в секунду, во сколько раз метод медленнее лидера, средняя уверенность; точность, полнота и F1 по каждому языку; матрицы ошибок. Затем два опыта — зависимость от длины входа и поведение на смешанном тексте — и выводы.

Пример. Все методы — 100 % (20 из 20), матрицы ошибок диагональные. Алфавитный метод в 21 раз быстрее метода N-грамм (0,39 против 8,28 мс).

Длина входа: документы нарезаны на окна по 10, 20, 40, 80, 150, 300, 600 и 1 200 символов — на всех длинах 100 %, для этой пары языков хватает одного-двух слов.

Смешанный текст (русский документ постепенно замещается немецким): метод N-грамм начинает отвечать «немецкий» при доле 45 %, нейросеть — при 50 %, алфавитный — при 52,5 %.

Как это работает. Точность — доля верных ответов. По каждому языку считаются

$$P = TP / (TP + FP), \quad R = TP / (TP + FN), \quad F_1 = 2PR / (P + R)$$

где TP — документы языка, распознанные верно, FP — чужие, ошибочно отнесённые к языку, FN — документы языка, отнесённые к другому. Матрица ошибок: строки — эталонный язык, столбцы — ответ метода. Все методы безошибочны, потому что кириллица и латиница не пересекаются и задача решается уже на уровне алфавита. Поэтому методы различаются ценой решения и поведением у границы: немецкие слова длиннее, и в смеси они дают больше N-грамм — метод N-грамм «переключается» раньше середины. Алфавитный метод дольше держится за русский, а нейросеть, обученная на данных, делит смесь ровно пополам.

4. Профили языков /profiles

Здесь видно, из чего состоят поисковые образы языков. Вверху — карточка обучающего корпуса и кнопка «Построить заново» (нужна после изменения корпуса). Для каждого метода — описание, параметры и самые частые признаки профиля каждого

языка с их долями; у алфавитного метода — выделенные по корпусу алфавиты, у нейросети — параметры и итоги обучения.

Пример. N-грамм: русский — «_», «о», «е», «а», «и», «т», «н», «с»...; немецкий — «_», «е», «п», «i», «r», «s», «t», «a»...; по 300 N-грамм на язык.

Алфавиты: немецкий — 28 букв (вместе с ä, ö, ü, ß); русский — 55: 33 буквы кириллицы и 22 латинские, которые встретились в русском корпусе чаще порога.

Нейросеть: 399 признаков, 32 скрытых нейрона, 220 эпох (сохранена лучшая — 185-я), 1 187 обучающих и 291 контрольный фрагмент; точность на контрольных фрагментах — 100 %.

Как это работает. ПОЯ строится один раз по обучающему корпусу (20–120 Кб на язык) и хранится в каталоге models/, ПОД — при каждом распознавании по тем же правилам. Буква входит в алфавит языка, если её доля в корпусе больше 10^{-4} . Нейросеть обучается обратным распространением ошибки с оптимизатором Adam (шаг 0,01, минипакеты по 32 примера). Минимизируется перекрёстная энтропия с L2-регуляризацией:

$$L = -\sum_i y_i \cdot \ln P_i + (\lambda / 2) \cdot \|W\|^2, \quad \lambda = 10^{-4}$$

где y — правильный ответ (1 у верного языка, 0 у другого). Сеть учится на фрагментах корпуса длиной 150, 300 и 600 символов, нарезанных с шагом 65 % длины (соседние перекрываются на 35 %): при обучении только на длинных фрагментах она проседала на коротком входе. 20 % корпуса откладываются для контроля до нарезки, чтобы одни и те же куски текста не попали и в обучение, и в контроль.

5. Свой текст /check

Поле для текста или HTML и загрузка файла (HTML, TXT). После кнопки «Определить язык» показываются язык, согласие методов, число букв и слов, время и таблица: расстояния до каждого языка, решение, уверенность и время каждого метода. Для текстов короче 40 букв выводится предупреждение. Если включён паук Пафнутий, перед отправкой он просит решить шахматную задачу; выключается переменной `TOLMACH_COMPANION=0`.

Пример. «Der Leuchtturm leuchtet im Nebel.» → немецкий у всех методов. Расстояния (русский / немецкий): N-грамм 0,990 / 0,650, алфавитный 0,995 / 0,385, нейросеть 1,0 / 0,0. «chisla» — русское «числа», записанное латиницей, — все три метода относят к немецкому: они узнают язык по алфавиту и буквосочетаниям, а транслитерация меняет и то и другое.

Как это работает. Текст проходит тот же конвейер, что документы коллекции: предобработка, построение ПОД для каждого метода, расстояния до ПОЯ и голосование.